



# I302 - Aprendizaje Automático y Aprendizaje Profundo

2<sup>do</sup> Semestre 2024

Guía de Ejercicios 1

- 
1. Sea una matriz  $A \in \mathbb{R}^{m \times n}$  de rango completo, se define el número de condición de la matriz  $A$  como:

$$\kappa(A) \triangleq \|A\| \cdot \|A^\dagger\|$$

Demostrar que:

$$\kappa(A) = \frac{\sigma_{\max}(A)}{\sigma_{\min}(A)}$$

**Sugerencia:** primero demostrarlo para el caso de  $m = n$  (matriz cuadrada), y luego para los casos  $m > n$  y  $m < n$ . Recordar las definiciones de  $A^\dagger$  para cada caso y usar la descomposición en valores singulares de  $A$ .

2. Sea  $f(x) : \mathbb{R}^n \rightarrow \mathbb{R}$  una función continua y doblemente diferenciable y  $g(z) : \mathbb{R} \rightarrow \mathbb{R}$  una función continua, doblemente diferenciable y monotónicamente creciente. Demostrar que si un punto  $x^*$  es mínimo local de  $f(x)$ , entonces también es un mínimo local de la función compuesta  $h(x) = g(f(x))$ .

**Sugerencia:** plantear las condiciones de optimalidad local de primer y segundo orden para  $f(x)$  y  $h(x)$ , y verificar que si se cumplen para  $f(x)$ , entonces también se cumplen para  $h(x)$ . Si quiere, primero puede demostrarlo para el caso particular de  $n = 1$  (es decir el caso en que  $x$  es un escalar) y luego generalizarlo para el caso en que  $x$  es un vector.

3. Derivar las ecuaciones para determinar los parámetros óptimos  $\mathbf{w}^*$  de un modelo de Regresión Lineal aplicando el principio de máxima verosimilitud, asumiendo que las muestras son independientes e idénticamente distribuidas con un ruido Gaussiano  $\mathcal{N}(0, \sigma^2)$ .

Demostrar que  $\mathbf{w}^*$  es el óptimo global, que maximiza globalmente la verosimilitud (probabilidad conjunta) de los datos de entrenamiento.

4. Derivar las ecuaciones para determinar los parámetros óptimos  $\mathbf{w}^*$  de un modelo de Regresión Lineal aplicando el principio de máxima verosimilitud, pero en este caso asumiendo además que la incertidumbre en el vector  $\mathbf{w}$  está dado por la distribución de probabilidad:

$$P(\mathbf{w}) = \mathcal{N}(\mathbf{w}_0, s^2 I) \quad (1)$$

Donde  $\mathbf{w}_0$  es un vector constante. Es decir, la distribución a-priori (antes de ver los datos) de  $\mathbf{w}$  es una Gaussiana de media  $\mathbf{w}_0$  y co-varianza  $s^2 I$ .

5. Derivar la función de costo “binary cross-entropy” para un problema de clasificación binaria con regularización  $L_2$  sobre los parámetros  $w$ , con hiperparámetro  $\lambda$ , aplicando el principio de máxima verosimilitud sobre el conjunto de entrenamiento.